SBPU-C4加速卡加速卡和服务器和软件 ---综合版本

1. 目录

1.	天机紧凑型	类脑加速卡简介	3
	1.1. 简述.		3
	1.2. 实物	描述	3
		特性	
	1.4. 规格	书	3
	1.4.1.	环境和可靠性规范	3
	1.4.2.	结构尺寸	4
	1.4.3.	卡间互联	4
2.	天机 SBPU-0	C4 类脑推理服务器简介	5
	2.2. 实物:	描述	5
	2.3. 功能特	特性	5
	2.4. 规格	书	6
	2.4.1.	原型手册	6
	2.4.2.	服务器尺寸	6
3.	天机类脑推	理服务器相关软件	7
	3.1. 驱动	说明	7
	3.1.1.	代码目录	7
	3.1.2.	加载驱动	7
	3.2. 运行	应用	7
	3.3. Dock	er 环境运行	9
	3.4. GUI	图形显示运行	9
4.	参考文档		9

修订记录

日期	修订版本	描述	作者
2019-06-20	1.0	初稿完成	类脑团队
2022-09-20	2.0	完成 SBPU	类脑团队
2023-04-20	2.2	1. 完成 SBPU,增加软件 相关说明 2. 增加三个参考文档	类脑团队
2023-05-20	3.0	增加参考文档	类脑团队
2023-06-14	3.1	增加参考文档	类脑团队

1. 天机紧凑型类脑加速卡简介

1.1. 简述

该加速卡可以与 SBPU-C4 类脑推理服务器互为搭配完成紧凑型加速服务器的部署,命名为 SBPU-C4 加速卡。

SBPU-C4 加速卡基于天机类脑推理芯片研发,最大同时支持 9 片天机人工神经网络芯片。

1.2. 实物描述

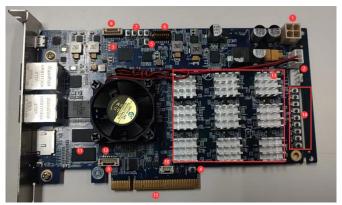


图 1 SBPU-C4 实物图

1.3. 功能特性

高性能的 AI 推理计算; 灵活部署; 极致能效。

1.4. 规格书

1.4.1. 环境和可靠性规范

表 1 提供 SBPU-C4 加速卡的环境和可靠性规范说明

参数	说明
Operating temperature	0°C-60°C
Operating humidity	5% to 95% relative humidity
Storage temperature	-10 ℃ to 75 ℃
Storage humidity	5% to 90% relative humidity
Mean time between failures (MTBF)	Uncontrolled environment: TBD at 35 ℃ Controlled environment: TBD at 35 ℃

表 1 环境和可靠性规范

1.4.2. 结构尺寸

SBPU-C4卡介绍如下:



图 2 SBPU 正面视图

- 1. 尺寸: 长*宽*高: 165mm* 25mm*97mm (标准单槽位);
- 2. 散热:采用主动散热和被动散热相结合方式;在天机芯片上安装散热片之外,还安装了散热风扇,采用了高导热系数的金属材质散热器结合风扇来实现散热;
 - 3. PCI-e 卡槽采用标准接口,可以插入到 PCI-e 插槽内;
 - 4. 电源:请提供 ATX 的四插口电源,如下图所示,电压是 12V,电流是 6A。 ATX-4P 连接器实物图如下所示:

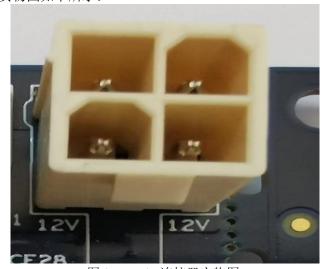


图 3 ATX-4P 连接器实物图

1.4.3. 卡间互联

不支持板间互联。

2. 天机 SBPU-C4 类脑推理服务器简介

2.1. 简述

SBPU-C4 类脑推理服务器支持 Intel E5-2600 V4 系列 CPU, 24 个 DIMM 槽位内存,采用(2+2) 冗余供电系统,实现系统稳定工作。整机散热采用风冷设计,精巧设计的散热通道加上 6 颗重载散热风扇,为服务器稳定工作提供保障。可以选装外置散热风扇,满足苛刻条件下服务器的稳定运行。4U 空间中部署 20 个人工智能前端推理模块,为推理提供强大的计算支持,并通过提高密度,降低总体服务器的部署数量,降低项目总体投资。

SBPU-C4 类脑推服务器采用模块化和异构解耦的系统设计,支持 SBPU- TianJiC4、PCI-e GPU、PCI-e FPGA 等多种类别的异构加速卡。

SBPU-C4类脑推理服务器业务场景是面向深度学习的在线推理业务环境。在线推理业务不同于离线训练,推理需要密集的计算能力,而推理则需要及时响应。和我们日常生活息息相关的主要是推理过程,而完成推理服务,需要大量的部署前端加速芯片,实时响应访问请求,对数据迅速做出判断。

SBPU-C4 类脑推理服务器互为搭配完成紧凑型加速服务器的部署,命名为 SBPU-C4 加速卡。

SBPU-C4加速卡基于天机类脑推理芯片,最大同时支持9个天机人工神经网络芯片。

2.2. 实物描述



图 4 SBPU-C4 类脑服务器

2.3. 功能特性

高性能 AI 推理计算

4U 空间可同时配置 10 卡 SBPU-C4 类脑计算卡,支持 180 片高效能比的天机 3.0 芯片,单机可提供高达 P 级计算处理能力。

配置2颗多核的顶配CPU,提供卓越通用计算性能。

灵活部署

4U 机箱, 2KW 供电设计使其适用于更广泛的数据中心部署环境,特别适合于功耗受限的机柜上架场景,使用更加灵活的集群部署方案,并能实现从硬件到应用的集成部署。 极致能效

系统内采用 12V 供电方案, 能效更高;

分层分区散热通道设计,可获得最佳的散热效率;

帮助 AI 用户高效完成 AI 基础设施和开发环境的构建,在享受更高计算性能的同时降低部署、运行成本。

2.4. 规格书

2.4.1. 原型手册

表 2 提供 SBPU-C4 类脑服务器的原型说明

参数	说明
形态	类脑异构服务器
处理器	2 个 Intel® Xeon® E5-2600 v4 处理器
主板	技嘉主板
内存	最多 24 个 DDR4 DIMM 插槽
操作系统支持	Ubuntu18.04
AI加速卡	支持 10 个 SBPU-C4 类脑计算卡,支持卡间互联
电源	4 个 80 PLUS 白金 2200W AC 热拔插电源模块 支持 N+N 冗余配置
风扇	6个热插拔风扇,支持 N+1 冗余
尺寸	高 x 宽 x 深:175mm*447mm*790mm

表 2 SBPU-C4 类脑服务器技术规格书



图 5 SBPU-C4 类脑服务器尺寸示意图

2.4.2. 服务器尺寸

4U 机架式服务器机箱,尺寸如 175.5mm(高)×482mm(宽)×793mm(深)。

3. 天机类脑推理服务器相关软件

3.1. 驱动说明

3.1.1. 代码目录

/home/pcie/drv 目录下是驱动程序 /home/pcie/test 目录下是应用程序

3.1.2. 加载驱动

root@6d86bdcf9445:/# cd /home/pcie/drv root@6d86bdcf9445:/home/pcie/drv#./load //或:

 $root@6d86bdcf9445:/home/pcie/drv\#\ insmod\ intel_fpga_pcie_drv.ko$

可在 /dev 目录发现 intel_fpga_pcie_drv 设备

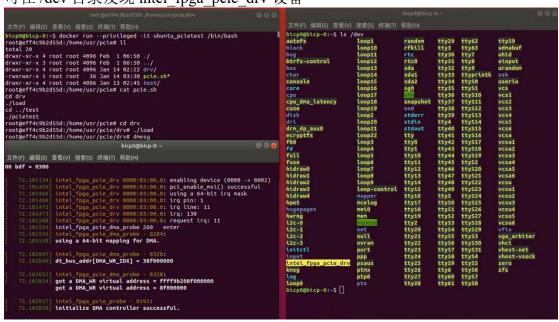


图 6 发现设备

3.2. 运行应用

root@6d86bdcf9445:/home/pcie/drv# cd ../test root@6d86bdcf9445:/home/pcie/test# ./pcietest

```
| Company | Comp
```

图 7 程序运行

3.3. GUI-QT 单机图形显示运行

请参考《基础操作-EBPU和 SBPU和 MDC和 BPU的 DEMO部署说明》

请参考《操作手册一-基础软件安装操作文档(X86前四步)》

请参考《SBPU灵活插卡操作手册》

3.4. Docker 环境运行

在一台主机上,安装运行 Docker 环境,及 PCI-e 相关程序:

- 1) 安装运行 Docker 环境;
- 2) 在 Docker 容器环境中,安装 PCI-e 驱动与接口应用程序;
- 3) 运行 PCI-e 驱动程序,运行 PCI-e 接口程序并作相关调整;
- 4) 导出包含 PCI-e 程序的相应镜像:
- 5) 在 Docker 容器环境中,运行 PCI-e 驱动与接口程序。

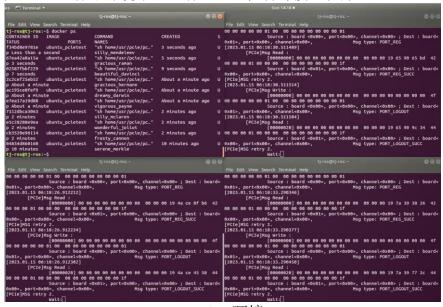


图 8 Docker 环境程序运行

4. Cloud-K8S 运行

请参考《docker 化和 K8S 入云说明.doc》

5.参考文档

- 1. 《有关于第一期和第二期的 FPGA 逻辑说明》---天机芯片相关的逻辑说明,其中第一期是时序精确控制器,第二期包括时序精确控制器和微码控制部分
- 3. 《EBPU 和 SBPU 场景-神经网络系统白皮书》---EBPU 和 SBPU 描述说明
- 4. 《有关于智能嵌入式形态和服务器加速卡说明.doc》---硬件相关

- 5. 《基于天机加速卡验证平台开发及原型手册 spec_20201105.doc》---平台原型说明
- 6. 《SBPU 说明手册--硬件分册-Ver1.0.doc》---硬件相关
- 7. 《EBPU 和 SBPU 场景软件原型手册 spec--V2 版本.doc》---原型说明
- 8. 《操作手册一-基础软件安装操作文档(X86 前四步)》---基础软件实现
- 9. 《天机 Sbpu-demo 环境搭建全流程文档---d》---Sbpu-demo 环境搭建
- 10. 天机芯片相关的逻辑说明《有关于第一期和第二期的 FPGA 逻辑说明》---其中第一期是时序精确控制器,第二期包括时序精确控制器和微码控制部 分
- 11. 请参考《基础操作-EBPU 和 SBPU 和 MDC 和 BPU 的 DEMO 部署说明》---部署说明
- 12. 请参考《SBPU 灵活插卡操作手册》---SBPU 加速卡说明
- 13. 《resnet 50 算法--dvpp 应用天机芯片-ROS&QT 环境框架介绍》--- resnet 50 算法说明
- 14. 《SBPU-FPGA-Logic-file 描述》---
- 15. 《SBPU 说明手册--硬件分册 (5)(1)(1)》---
- 16. 《PCI-e 软件日志使用说明 (2)》---
- 17. 《Dvpp 接收核验终端开发及使用说明》---
- 18. 《天机 Sbpu-demo 环境搭建全流程文档》---
- 19. 《图像识别 PCI-e 接口软件开发使用说明》---
- 20. 《天机 X1 芯片控制器上位机功能对齐说明 20210816》---
- 21. 《天机控制器时序精确级模块-数据帧格式与数据位对照 1213》---
- 22. 《天机 X 芯片控制器设计与说明文档 v4.0 20220427---简述版本》---
- 23. 《天机时序控制器操作步骤 20220420》---
- 24. 《天机时序控制器操作步骤 20220420----zlb》---
- 25. 《NOC-RW 调试文档》---NOC-RW 模块异常调试
- 26. 《Pci-e 的 CSR 文档》---Pci-e 模块异常调试
- 27. 《天机设备驱动与应用程序安装使用说明 A》
- 28. EBPU 平台请参考其他文档